



Universidad de
los Andes
Colombia

Educación
Continua
Vicerrectoría Académica

Diseñando un sistema de datos para *BetterStore*

Ejercicio de clase: Creación de una Data Warehouse



Contexto

La empresa **BetterStore** es una cadena regional de tiendas. En los últimos años ha venido acumulando datos en distintos departamentos: marketing, comercial, operaciones y fidelización. Cada área ha gestionado sus propios archivos Excel, sin integrarse ni tener reglas comunes de calidad. El resultado: bases desorganizadas, duplicadas, difíciles de analizar, y con múltiples errores.

La dirección general quiere comenzar a tomar decisiones basadas en datos confiables, integrados y bien estructurados. Ustedes, como equipo de analistas, han sido contratados para diseñar un modelo de datos que permita responder preguntas clave del negocio a partir de estos silos. Para ello, trabajarán directamente sobre los archivos en crudo, que deberán limpiar, modelar y cargar en una base de datos en Supabase.

Para ello los equipos de BetterStore nos proporcionaron cuatro archivos CSV:



Universidad de
los Andes
Colombia

**Educación
Continua**
Vicerrectoría Académica

1. **marketing.csv**: campañas promocionales con fechas, canales, descuentos y producto asociado.
2. **inventario.csv**: información de productos, precios, stock y categorías.
3. **ventas.csv**: historial de ventas con fechas, canales, productos, clientes y cantidades.
4. **clientes.csv**: datos de clientes como nombre, email, teléfono, ciudad y fecha de registro.

Estos archivos pueden contener errores típicos: nombres mal escritos, formatos inconsistentes, columnas con ruido, valores nulos o duplicados.

La tarea para la que nos contrató BetterStore es configurar un Data Warehouse (artesanal). Esto quiere decir que no tendrá automatizaciones, pero tendrá toda la configuración y arquitectura de una bodega de datos. Las tareas que se deben realizar:

1. Crear cuatro etapas en su base de datos de Supabase:
 - raw: donde cargarán los CSV originales.
 - stg: donde guardarán una versión “limpia” de los datos.
 - core: donde crearán las dimensiones y el hecho (modelo estrella).
 - bi: donde se ubicarán los reportes consolidados.
2. Importar los archivos CSV en tablas del esquema raw:
 - raw.marketing, raw.inventario, raw.ventas, raw.clientes
3. Crear tablas en el esquema **stg** que contengan datos limpios:
 - Estandarizar texto (trim, lower, títulos)
 - Convertir formatos de fecha y número
 - Eliminar o tratar duplicados, nulos y errores evidentes
 - Unificar categorías o canales inconsistentes
4. Crear las tablas finales en el esquema core:
 - Pensar un modelo de datos (quizá tipo tabla de hechos y dimensiones) de acuerdo con su criterio
 - Generar llaves (bigserial o UUID) como PK (Usar ChatGPT para esto)



Universidad de
los Andes
Colombia

**Educación
Continua**
Vicerrectoría Académica

Nota: Pueden usar solo SQL. No es necesario programar nada ni limpiar los archivos por fuera.

Una vez creado su modelo, deberán responder las siguientes preguntas desde la base core:

- ¿Cuántos clientes únicos hay y en qué ciudades se concentran?
- ¿Cuáles son los 5 productos más vendidos por cantidad y por ingresos?
- ¿Qué productos se están vendiendo con pérdida (costo > precio)?
- ¿Cuál ha sido el impacto de las campañas en las ventas de los productos promocionados?
- ¿Qué canales de venta son más rentables?
- ¿Cómo se comportan las ventas por mes y por día de la semana?
- ¿Cuál es el margen total y promedio por producto, categoría y canal?



Taller

Día 1

Para abordar esta misión va a ser importante involucrar su criterio en el proceso para considerar entre diferentes opciones cuál puede ser la más adecuada para una base de datos analítica. Del mismo modo, es fundamental poder dialogar con los datos y con el contexto del negocio para explorar y desarrollar de manera estructurada y pertinente los procedimientos.


El caso de estudio se va a trabajar en dos sesiones. En esta primera sesión la idea es enfocarse en el entendimiento de los datos, el modelado y la creación de tablas. En la segunda sesión se dedicará mayor tiempo al análisis de la información.

¡Mucho éxito!


Entendimiento del negocio y reconocimiento de los datos (30 min)

Para comenzar se sugiere familiarizarse con las fuentes de información originales. Recuerden: estas tablas fueron armadas por cada uno de los departamentos pensando en su propia operación. No están en principio relacionadas, ni estandarizadas de ninguna forma.


5. Observe las tablas. Encontrará que pueden ser muy pesadas para manejarlas en Excel. Cree un Schema de postgres (análogo a un dataset de BigQuery) en que pueda cargar los datos en estado bruto (raw).




Para esto podrá ir al editor de tablas de Supabase y crear un schema manualmente.



6. A partir de las fuentes de datos, cree las tablas. Dado que no conocemos el esquema inicialmente puede utilizar el editor de tablas de Supabase para cargar la información desde csv tal cual viene. Para esto, haga clic en nueva tabla, seguido de “importar datos desde CSV”.




7. Conéctese a su base de datos desde Beekeeper. Recuerde las instrucciones del taller final del módulo 3. Tome la cadena de conexión e impórtela desde URL. Recuerde poner la contraseña de su base de datos.



Si olvidó la contraseña de su base de datos puede ir a Project settings > Database > Restore password.

8. Observe los campos y tome nota:
 - a. ¿Qué información contiene cada tabla? ¿Quiénes pudieron haber sido los usuarios iniciales de la información?
 - b. ¿A qué corresponde cada unidad de observación en cada tabla?
 - c. ¿Tienen sentido el tipo de datos con que cargaron los datos inicialmente?

Al final debería terminar con una capa raw similar a la siguiente:




Preparación de los datos - diagnóstico de calidad (20 minutos)

Ahora puede tener en cuenta todas las observaciones de la etapa inicial. Haga una revisión básica de sus tablas, corra algunas validaciones para notar si los valores están estandarizados



(o hay cosas escritas de diferentes formas). Para esto podemos ingresar a cualquier servicio de modelo de lenguaje grande (LLM):



9. Apóyese en modelos de lenguaje como Gemini o ChatGPT para efectuar algunas limpiezas como duplicados, estandarizar valores. Para esto:
- Describale la estructura de su tabla (columnas, tipos de datos, unidad de observación)
 - Describale la tecnología que está usando, en este caso una base de datos de postgres.
 - El lenguaje para hacer las transformaciones, en este caso SQL.
 - Una descripción del contexto del negocio de los datos.
 - Comuníquese su preocupación de calidad para que le de opciones para diagnosticarlo y manejarlo.

Nota: en esta primera parte intente diagnosticar los posibles problemas de calidad de datos. Después vamos a manejarlos.

Nota 2: tenga en cuenta que hay tablas en las que tiene sentido que haya registros duplicados, mientras que en otras no. Ej. Un dato de quiz puede aparecer duplicado en una tabla de intentos de quices. Pero un dato de quiz no debería aparecer duplicado en una tabla de quices.



Punto sugerido para break.

Preparación de los datos - manejo de temas de calidad (20 minutos)

1. Ahora cree un archivo nuevo de SQL. Apóyese en su LLM para manejar los problemas de calidad de datos que identificó. En caso de que no haya encontrado algún problema de calidad de datos en sus validaciones previas (¡que no hay problema!) puede tomar alguno de los siguientes, o ambos: hay clientes duplicados en la tabla de clientes clientes + los nombres de los productos no están estandarizados en la tabla de inventario (están escritos de múltiples maneras, con mayúsculas y minúsculas).


¡Tengan en cuenta! Para limpiar los datos **no vamos a actualizar las tablas de la capa raw**. En lugar de eso vamos a crear tablas nuevas en stg a partir de la selección sobre tablas en la capa raw. Esta es otra forma de crear tablas CREATE TABLE AS (CTAS) adicional a la forma que ya hemos visto de crear tablas detallando el scheme:

```
-- 1. TABLA INVENTARIO --
DROP TABLE stg.inventario;

CREATE TABLE stg.inventario
AS
SELECT *
FROM raw.inventario;
```




Guarde este query. Vaya organizando sus queries en una estructura organizada de carpetas que le permita ir transformando desde sus datos en etapa raw de manera replicable a futuro. Por ejemplo, a continuación, en la carpeta llamada como cada capa, almacenamos los query que crean tablas en el correspondiente schema de postgres.



Modelado (20 minutos)

Finalmente, procedan a diseñar un modelo de datos. Tengan presente que a partir de los campos iniciales en el schema stg, hay múltiples formas para relacionar sus datos. Habrá que definir identificadores, llaves, etc.

10. Redacte un requerimiento de información con lo que ya conoce de sus datos. Qué información necesita almacenar.
11. Elabore un boceto de servilleta de su modelo relacional, piense qué tan normalizado quiere que queden las tablas, considerando que esta es una base analítica.

Puede utilizar una herramienta como <http://draw.io/> o la que sea de su preferencia para bocetar el modelo. Guárdelo en sus archivos de la bodega de datos. Lo vamos a utilizar la próxima clase.